INNOVATE

AI/ML AND DATA EDITION

FEBRUARY 22, 2024

aws INNOVATE
AI/ML AND DATA EDITION

AWS에서 GenAI RAG를 구성하기 위한 다양한 Vector database에 대해 알아보기

전소영

Solutions Architect | Migration and Modernization, AWS

목차

1. 생성형 AI를 활용한 서비스의 도전과제
2. 검색 증강 생성 (RAG)와 기술 요소
3. AWS에서 제공하는 다양한 벡터 데이터베이스
4. AWS의 완전 관리형 End to End RAG 워크플로우
   - Amazon Bedrock 지식 베이스 데모

질문 : 생성형 AI(GenAI)란 무엇인가요?

대화, 스토리, 이미지, 동영상, 음악 등
새로운 콘텐츠와 아이디어를 생성하는,

대규모 데이터를 기반으로 사전 학습된 초거대 모델로,
일반적으로 파운데이션 모델(FM)이라고 합니다.

전통적 기계 학습 모델과 파운데이션 모델 비교

정제 된 충분히 많은 데이터로 **특정 목적 포커스**된 학습/배포 과정을 목표 지능 수준까지 반복 수행

초거대 용량 데이터로 초거대 FM을 사전학습 시킨 후 **특정 목적 태스크 범용** 적용

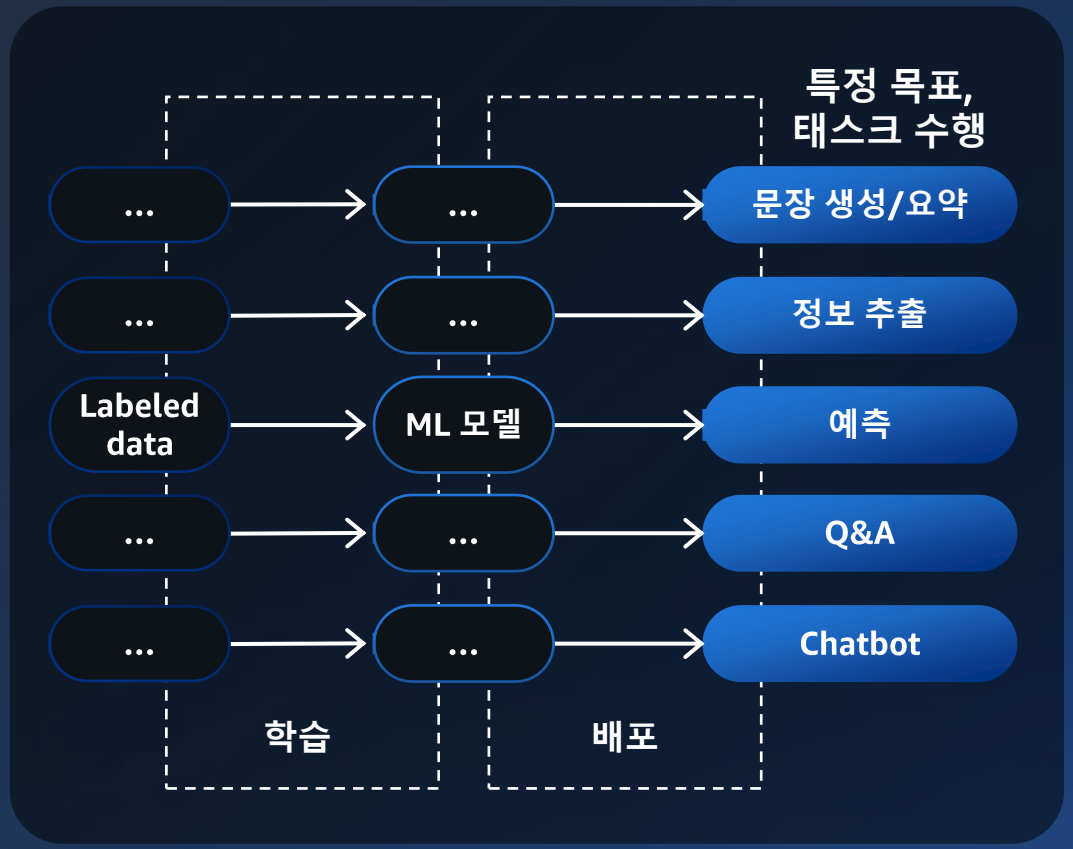

전통적 기계학습 모델

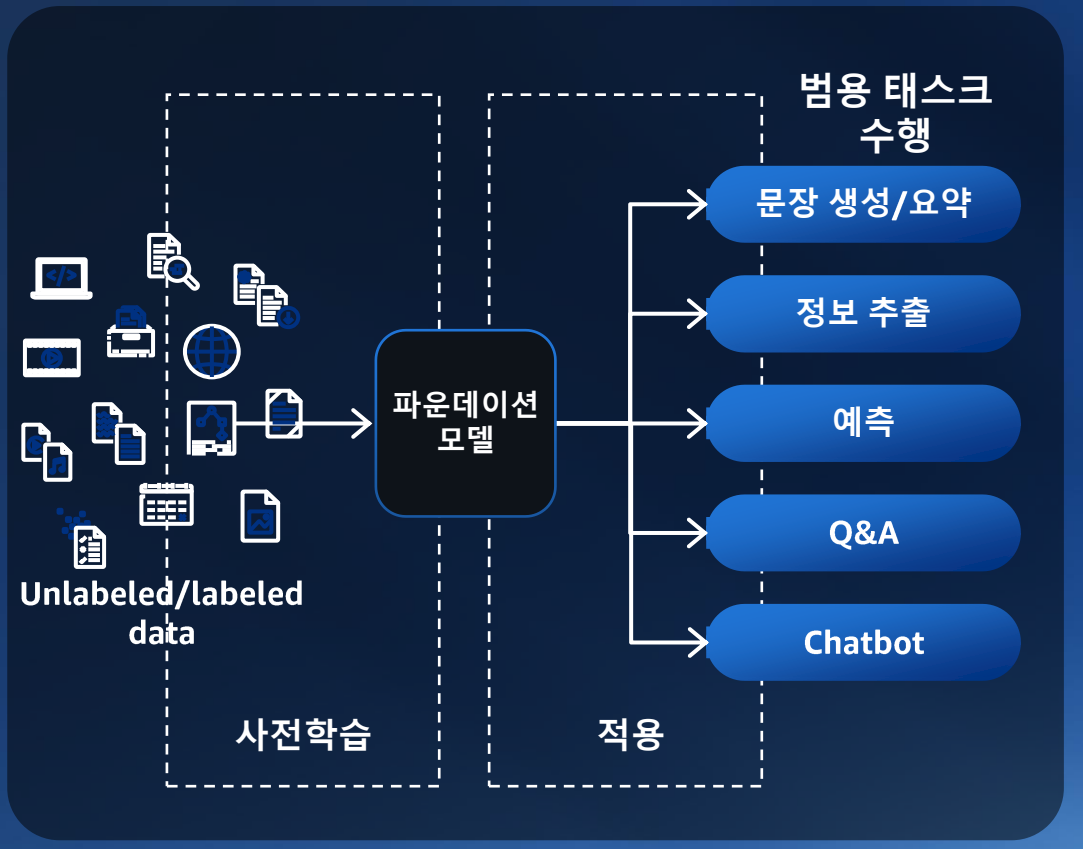

파운데이션 모델

생성형 AI 활용 서비스 개발 시 도전 과제

학습 데이터에 의존적

기한이 지난 정보

부정확한 사실을
제공하는 환각현상

맥락(컨텍스트)
이해 및 추론의 부족

파운데이션 모델의 도메인 적응 방법

1. 컨텍스트 기반 프롬프트 엔지니어링
2. 검색 증강 생성(RAG) 활용
3. 사전 훈련된 파운데이션 모델 파인 튜닝
4. 자체적인 파운데이션 모델 훈련

사전 훈련된 파운데이션 모델을 그대로 활용

파운데이션 모델에 도메인 적응 비용과 효과성

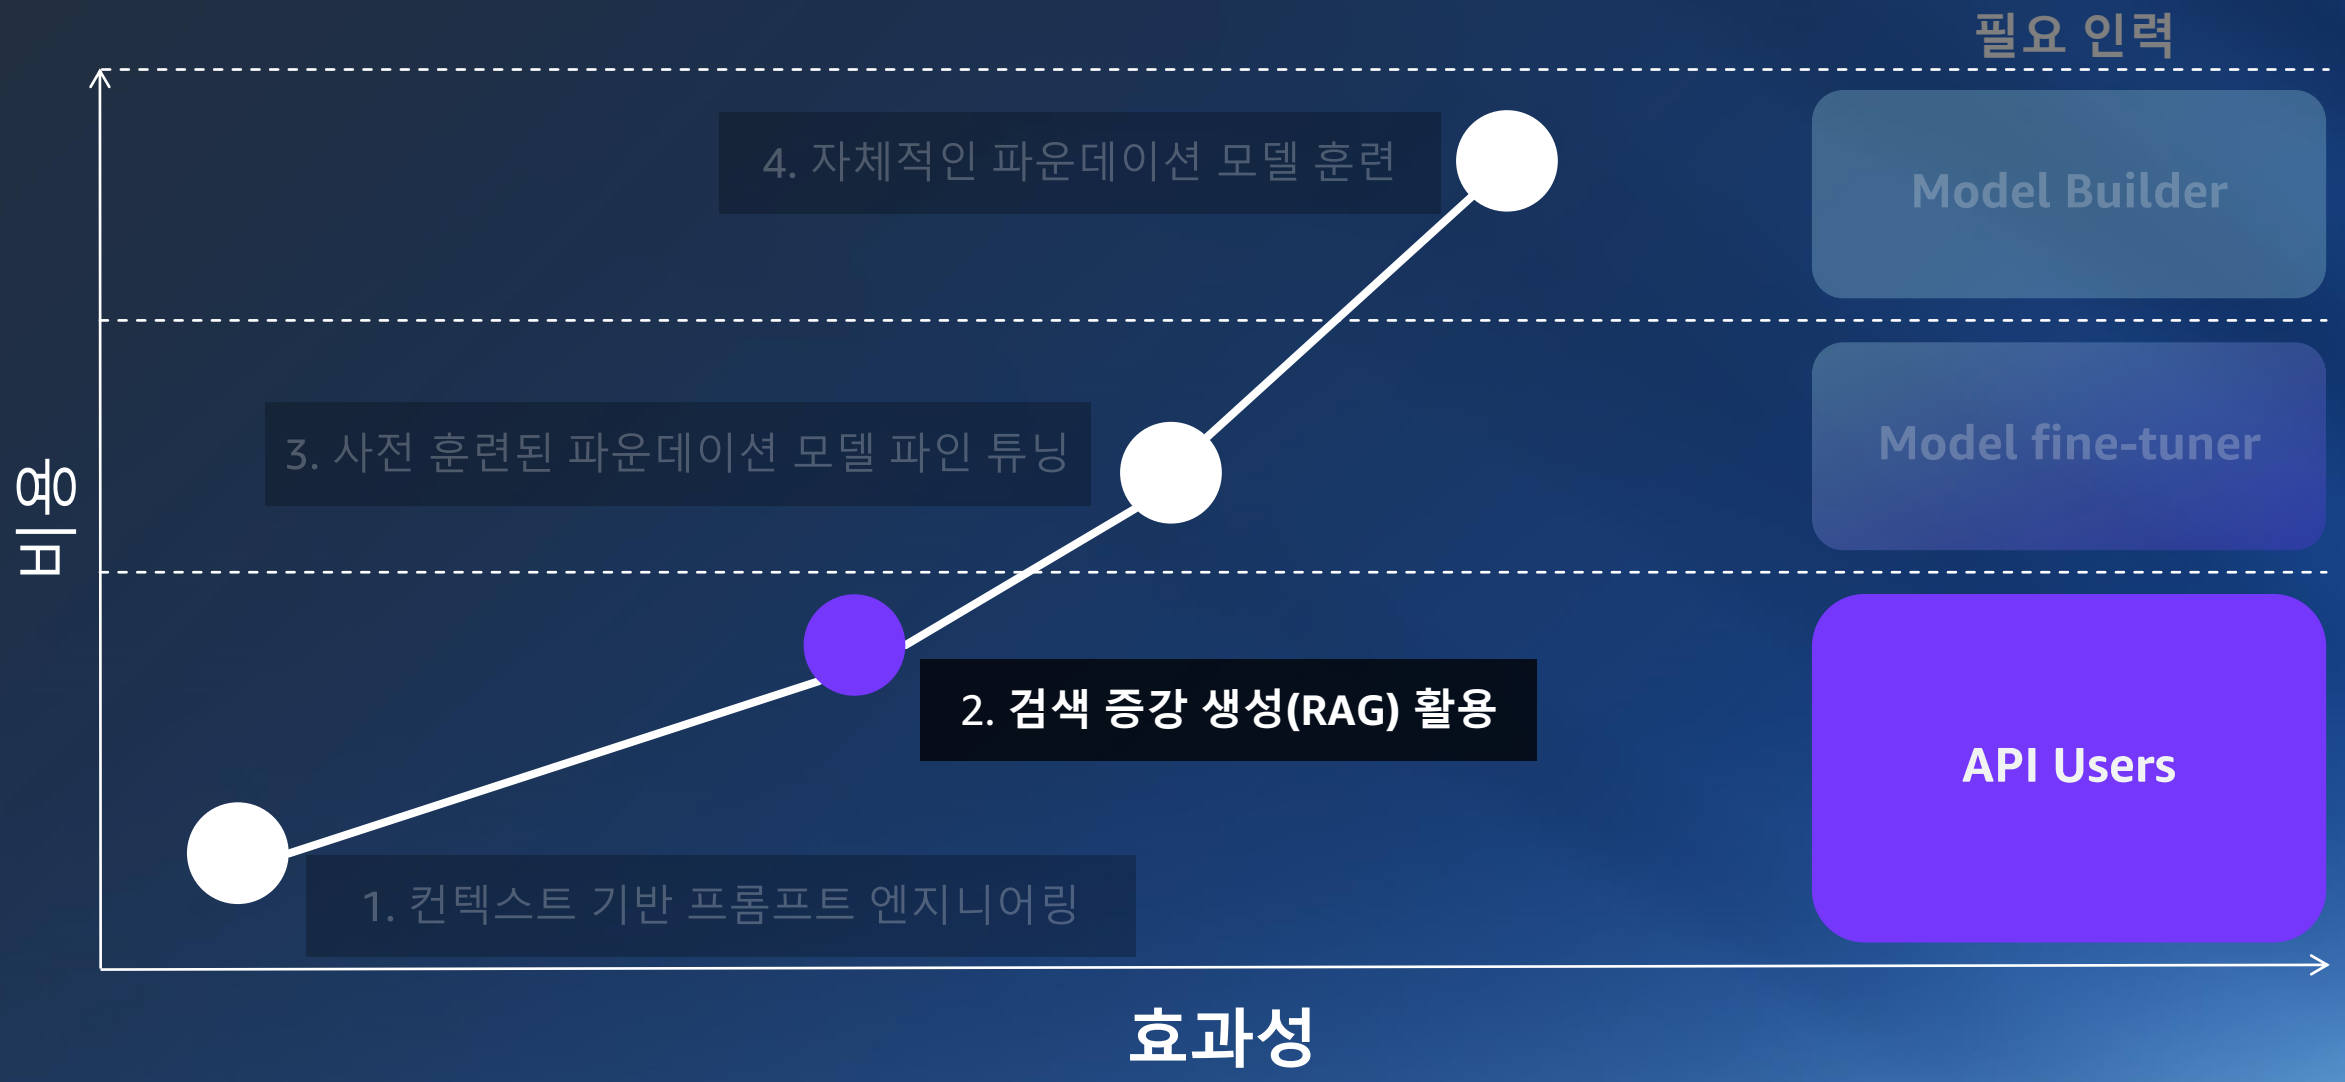

검색 증강 생성 (RAG)

1 최신/특정 도메인 지식 베이스 생성 (배치성 작업)

검색 증강 생성 (RAG)

2 사용자 질문 제출 (실시간)

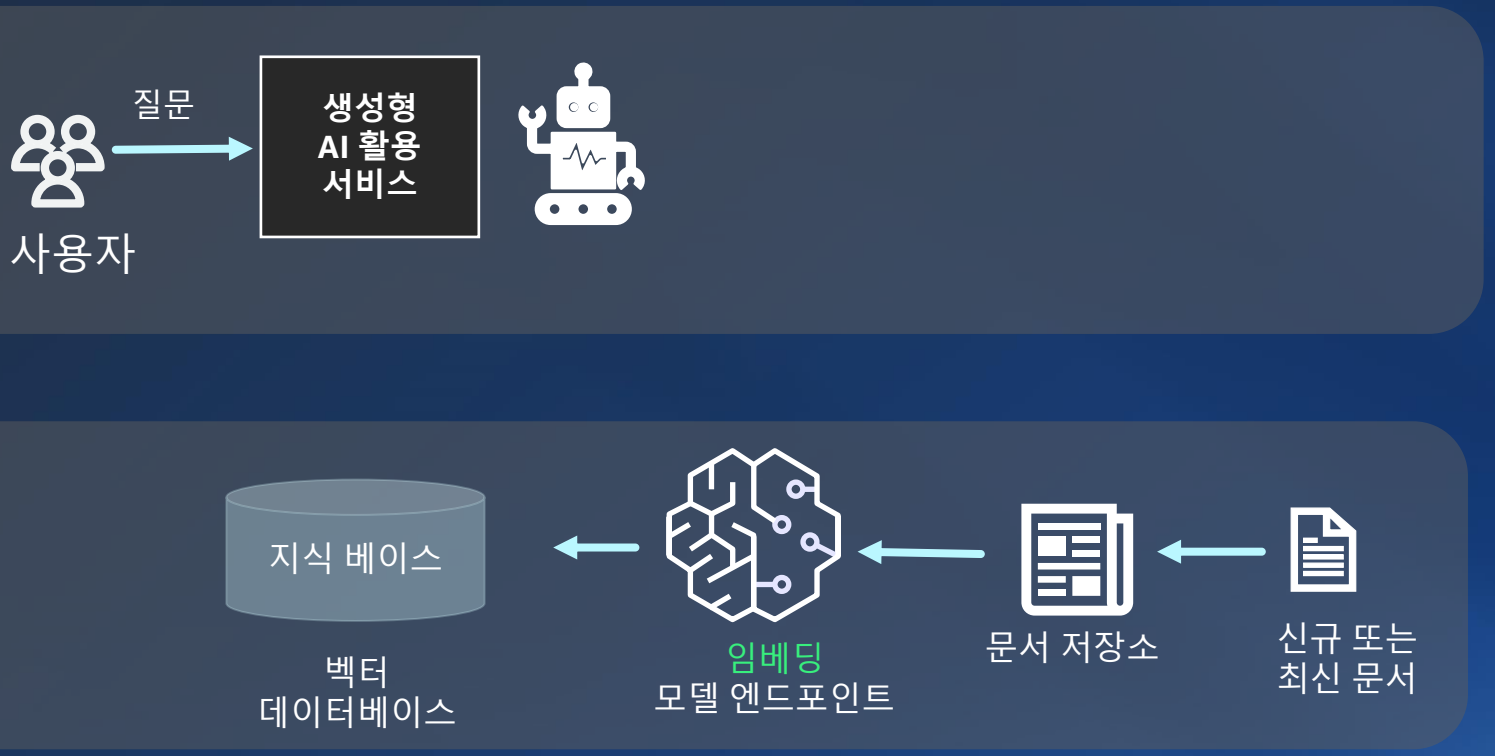

검색 증강 생성 (RAG)

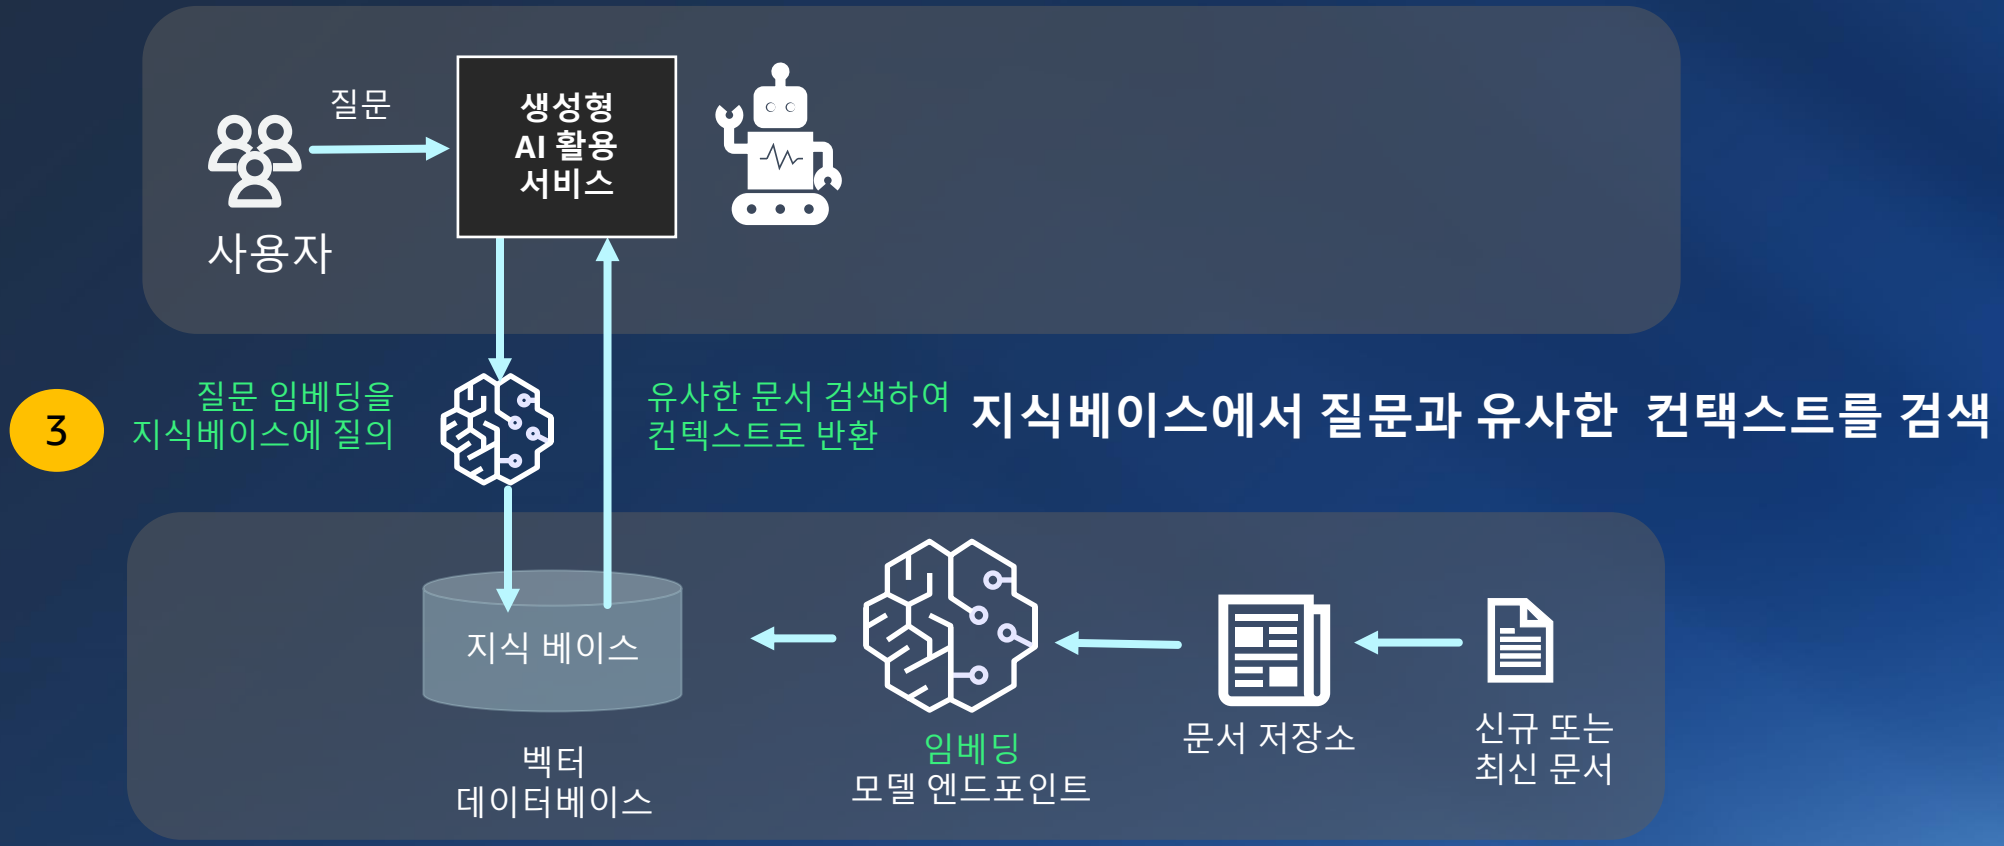

검색 증강 생성 (RAG)

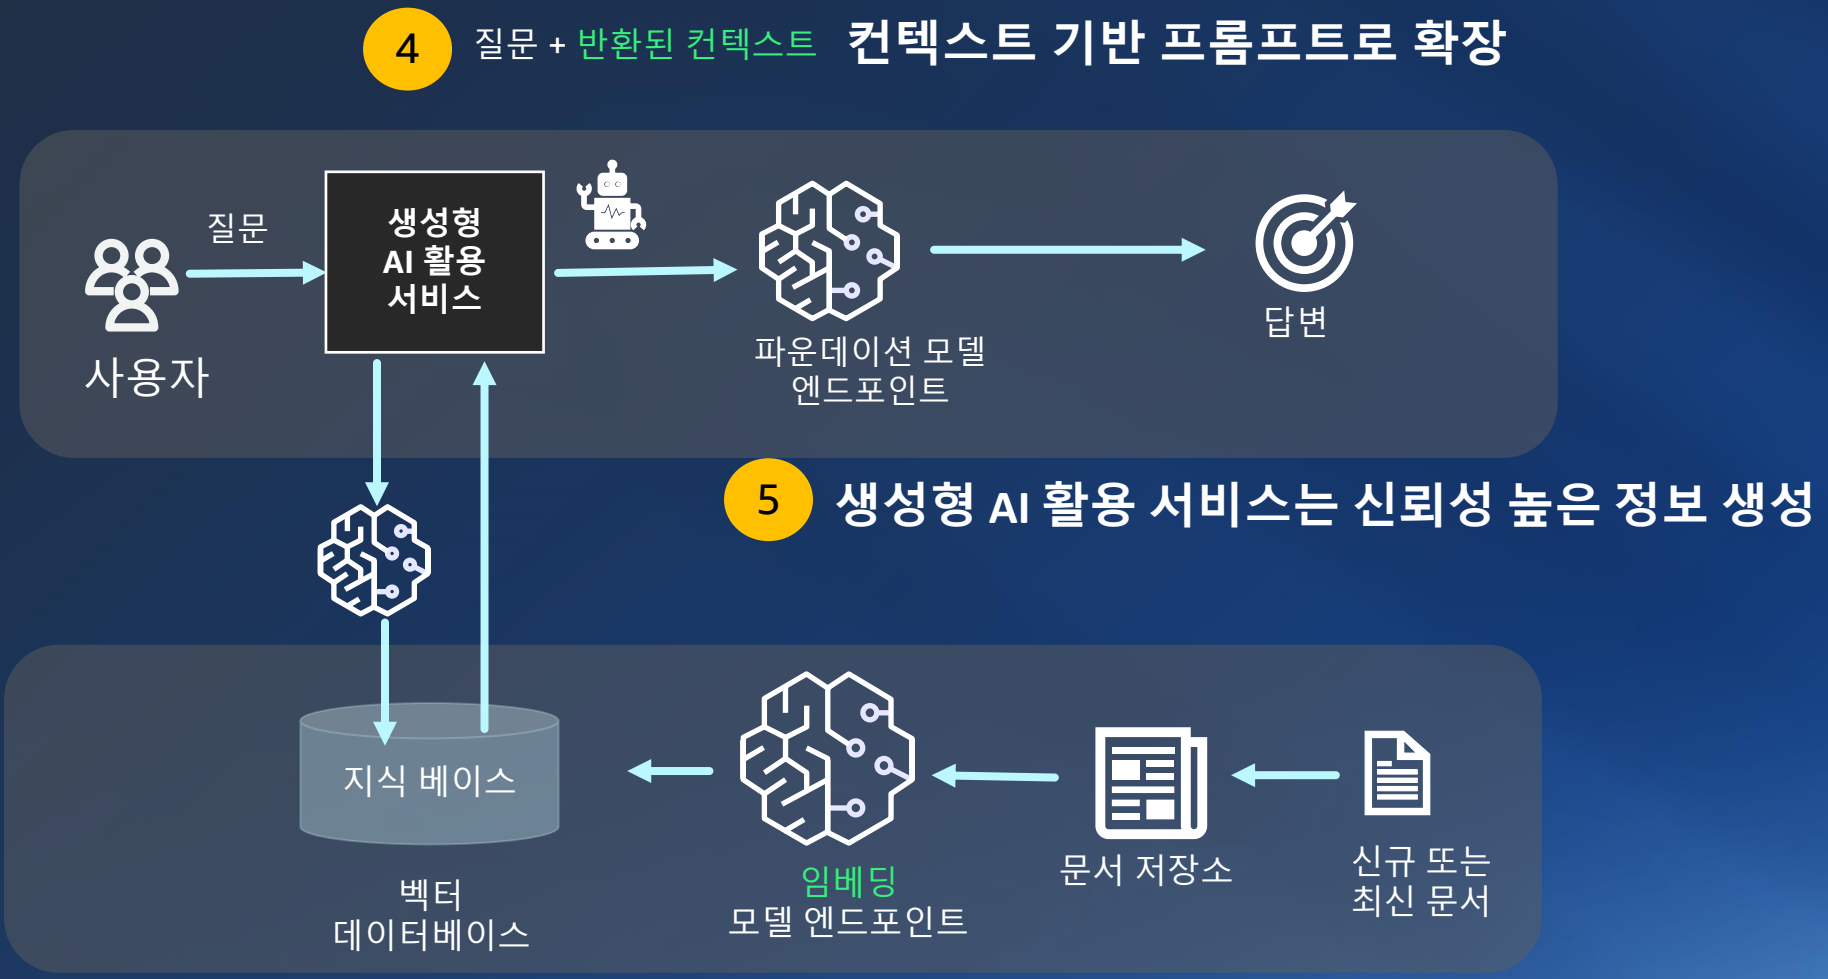

검색 증강 생성 (RAG)

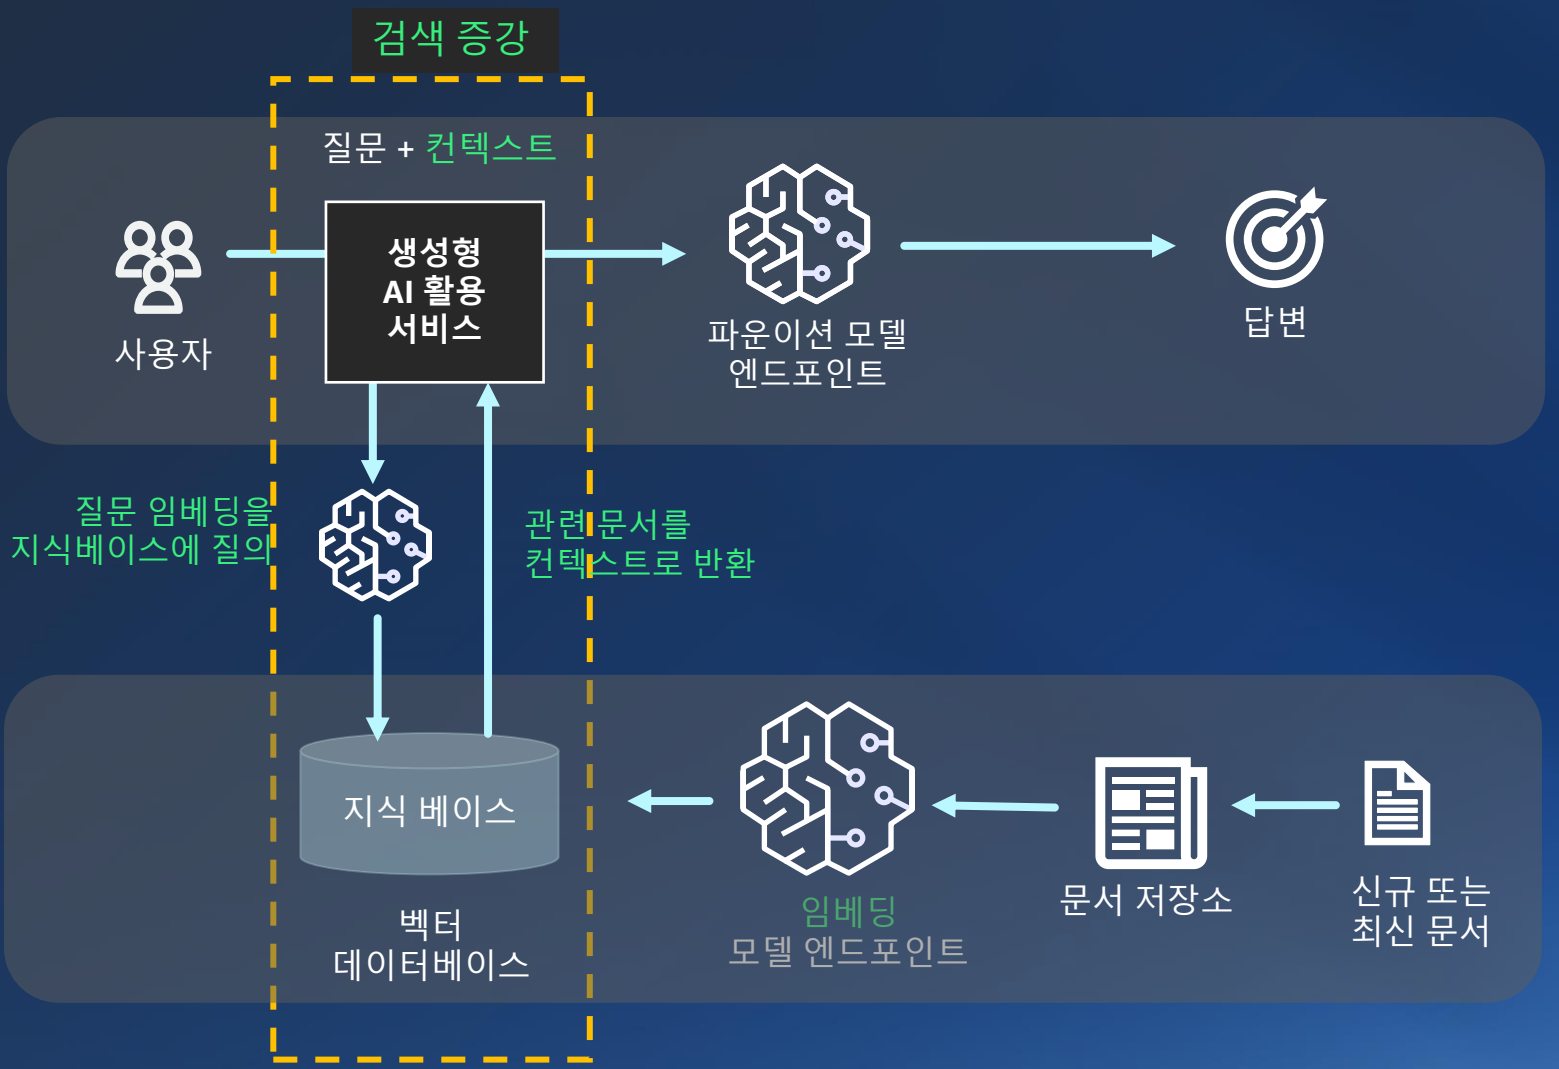

RAG의 지식 베이스 구축 프로세스

AWS에서 지원하는 벡터 데이터베이스

실시간 벡터 임베딩을 저장, 변경, 관리 및 고성능 벡터 유사성 검색 알고리즘을 제공하는 벡터 저장소

AMAZON OPENSEARCH SERVICE

AMAZON AURORA POSTGRESQL

AMAZON RDS FOR POSTGRESQL

NEW!!

AMAZON MEMORYDB FOR REDIS

NEW!!

AMAZON DOCUMENTDB

NEW!!

AMAZON NEPTUNE

NEW!!

AMAZON DYNAMODB

VIA ZERO-ETL

벡터 Vector

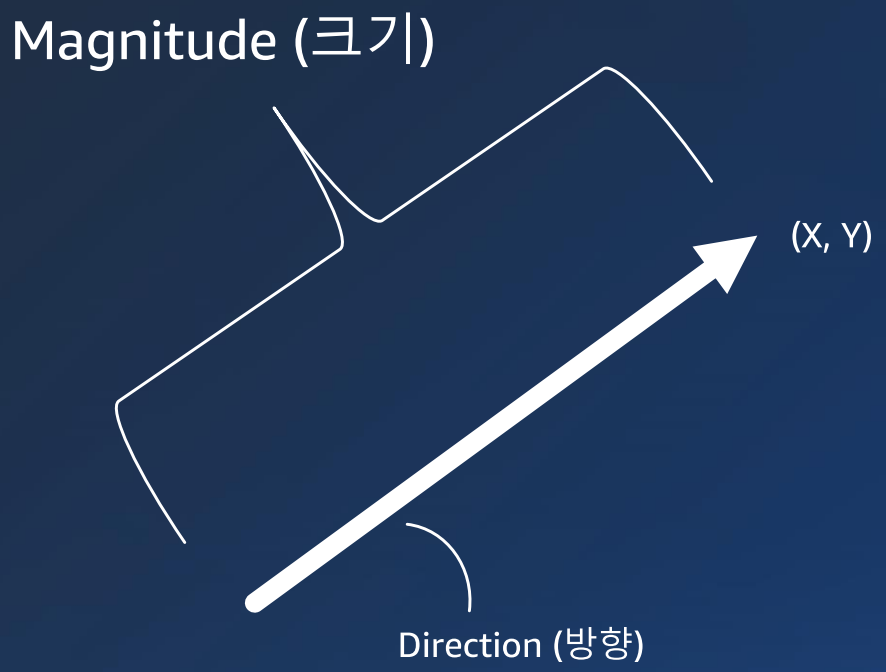

N 차원 의 원소들의 배열, 1xN 행렬, 행 벡터

X	Y	Z	……...	N
0.275	0.827	-0.133	0.298	0.023	-0.394

임베딩 Embedding

임베딩은 단어, 문장, 문서, 이미지 등의 데이터를 모델의 인코더를 활용하여 컴퓨터가 이해할 수 있는 형태의 벡터로 변환하는 과정 또는 변환된 벡터

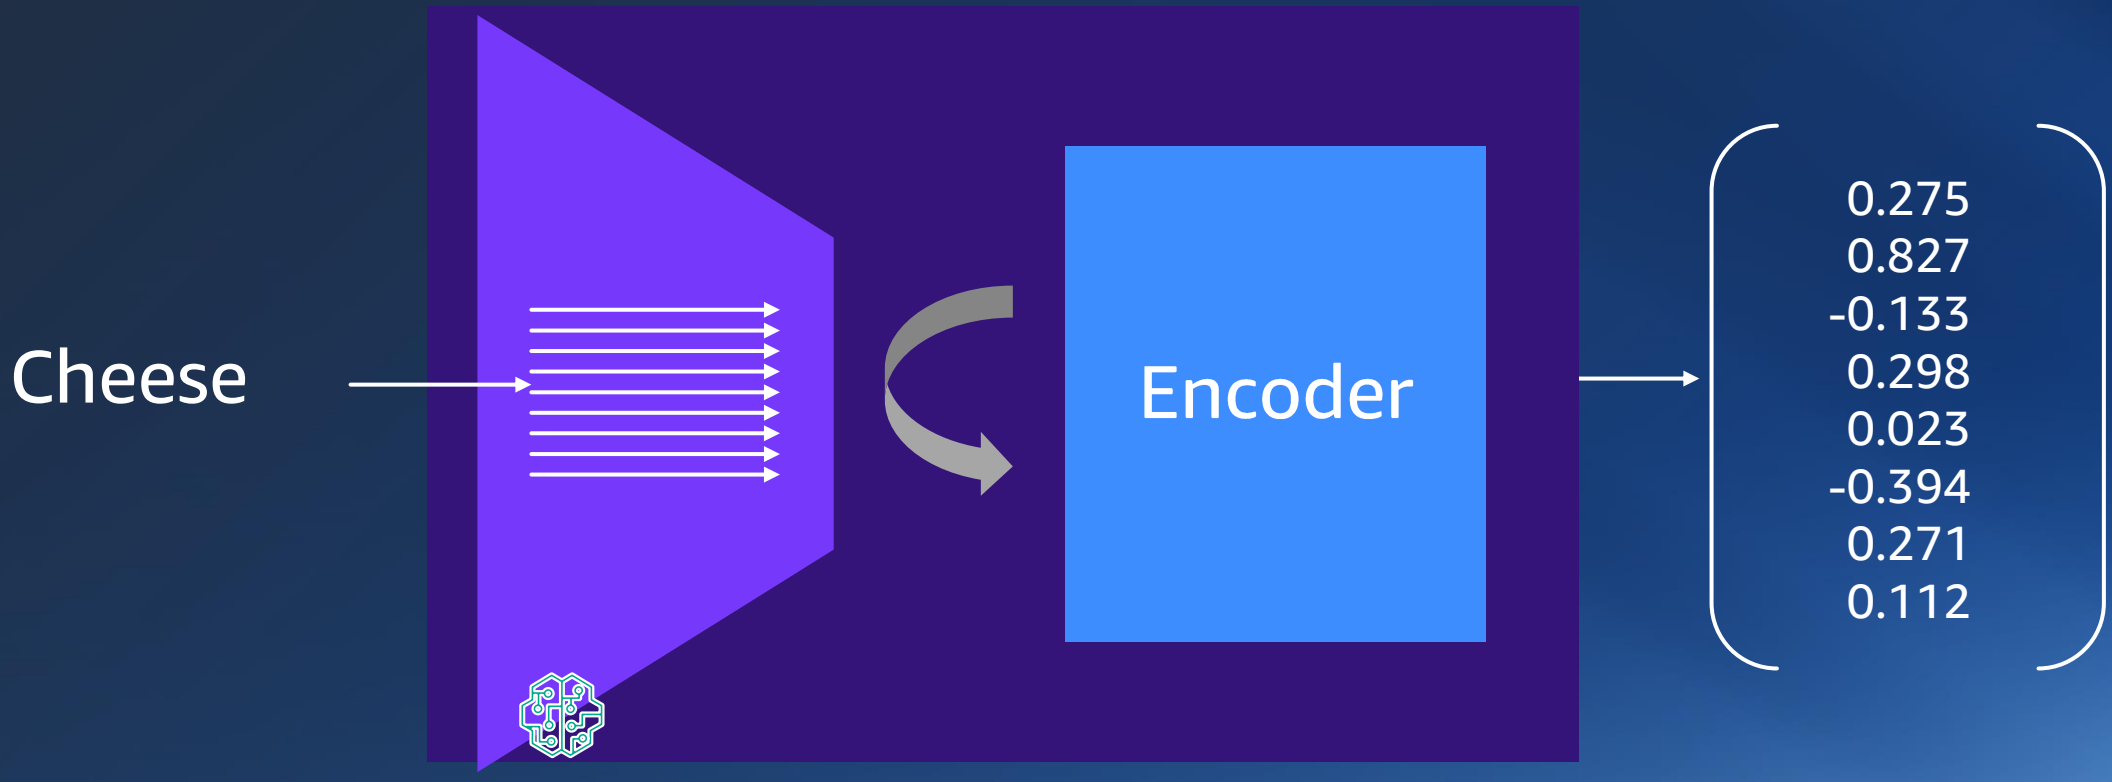

벡터 공간 Vector space

왕 – 남성 = 여왕

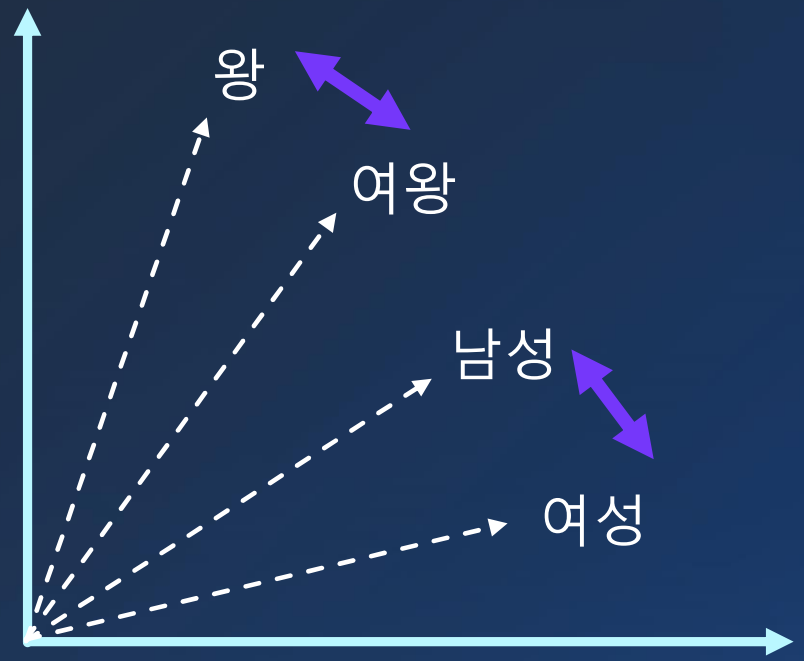

클러스터링

벡터 간의 유사성 측정

유클리드
(Euclidean, L2)

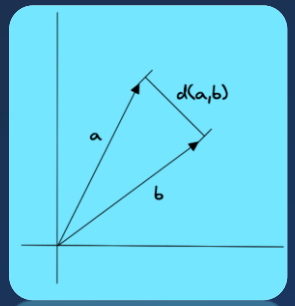

$$d(\mathbf{p}, \mathbf{q}) = \sqrt{\sum_{i=1}^{n} (q_i - p_i)^2}$$

코사인 유사성
(Cosine Similarity)

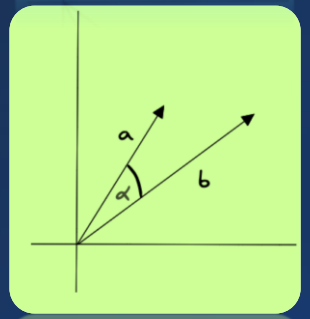

$$sim(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{||\mathbf{a}|| \cdot ||\mathbf{b}||}$$

내적
(Inner Product)

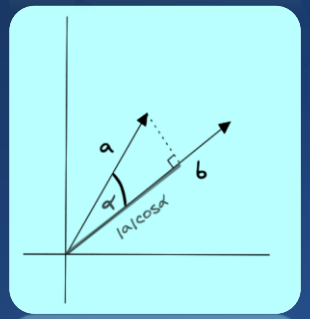

$$\mathbf{a} \cdot \mathbf{b} = |\mathbf{a}||\mathbf{b}| cos\alpha$$

벡터 검색 알고리즘

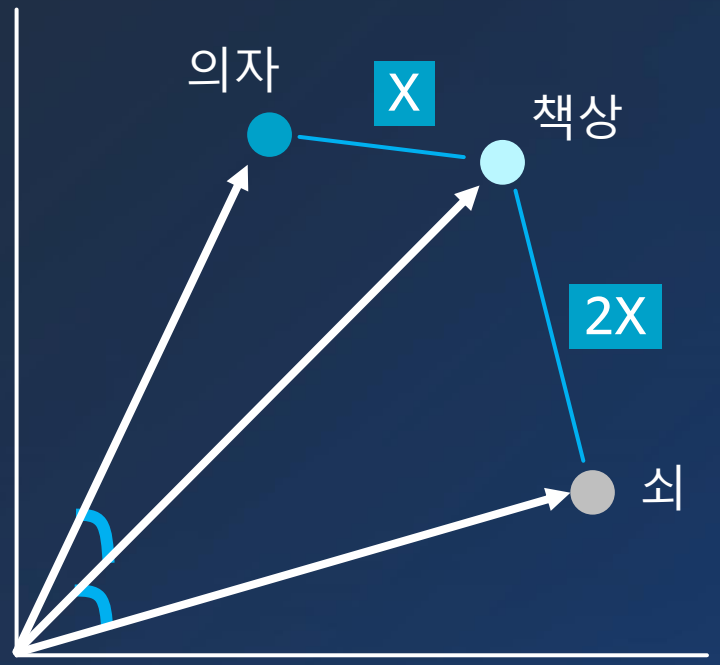

k-NN k-최근접 이웃
k-Nearest Neighbors

A-NN 근사 최근접 이웃
Approximate Nearest Neighbors

재현율(Recall)

Ex) 재현율 80%

대규모 벡터 검색을 위한 ANN 기반 인덱싱 알고리즘

IVFFlat

Inverted File with Flat Compression

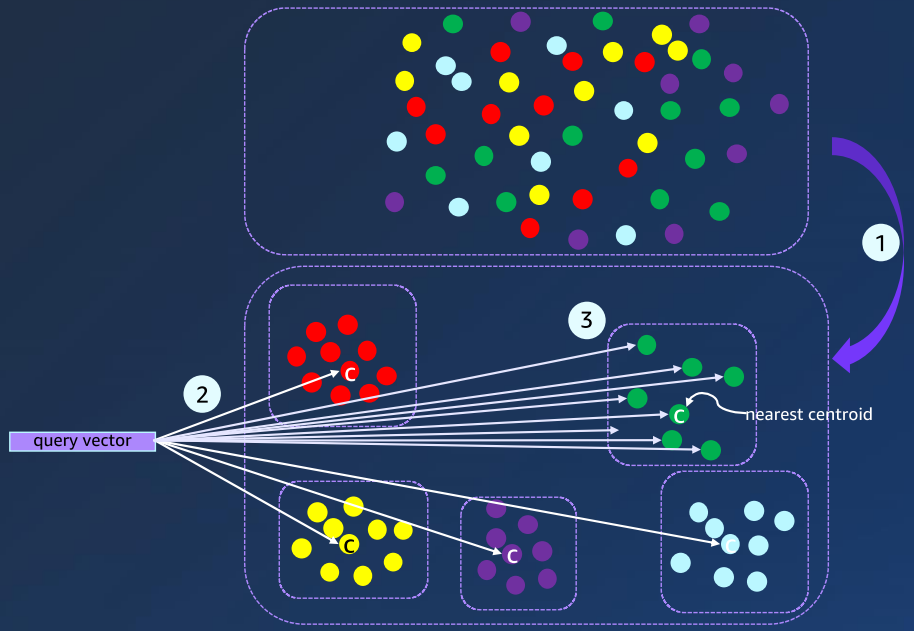

- K-means 기반 버킷 구성
- 빠른 인덱싱
- List, Probes 매개변수

HNSW

Hierarchical navigable small world

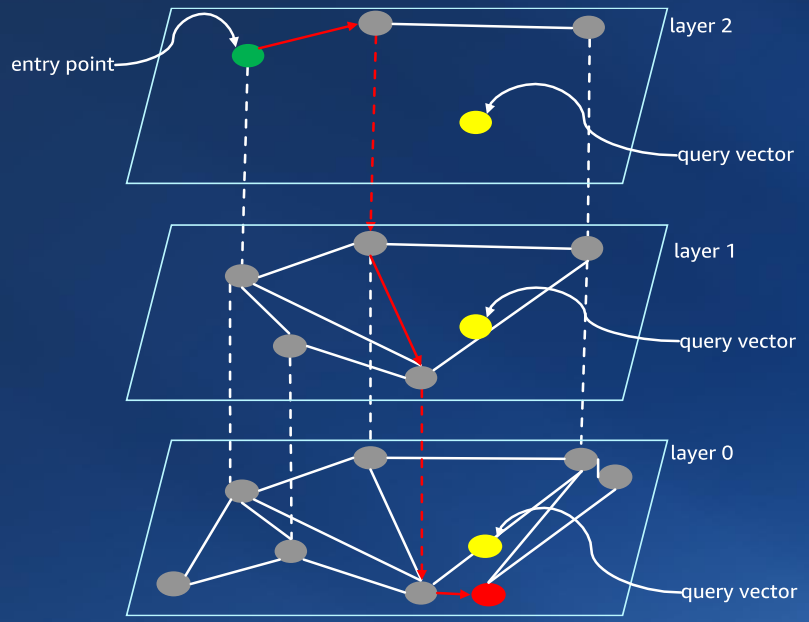

- 그래프 기반 , 이웃 벡터 레이어구성
- 대규모 데이터 세트의 고성능, 높은 재현율
- M, ef_construction, ef_search 매개변수

Amazon OpenSearch 벡터 엔진

사용의 용이성

서버리스를 지원하여 간단한 API로 시작가능.
용량을 계획, 규모를 관리할 필요성 제거

고성능 및 대규모 벡터 유사성 검색

수천 차원의 수십억 벡터를 밀리초 단위로 저장,
업데이트, 검색 가능

벡터 검색과 키워드 검색 하이브리드

DSL을 통한 키워드 검색 및 랭킹 기능을 사용하여
키워드 검색과 벡터 검색을 결합한 검색 가능

비용 효율성과 안정성 최적화

오픈서치의 스토리지 수직 및 노드의 수평 확장성
활용하여 프로덕션의 비용 효율성과 안정성 확보

엔터프라이즈급 보안

암호화 및 VPC 엔드포인트를 통해 데이터 저장
및 이동 시 데이터 보안, 인증 및 액세스 제어

OpenSearch의 벡터 데이터베이스

- K-NN 플러그인 벡터 엔진 제공

```
PUT my-index
{
  "settings": { "index.knn": true },
  "mappings":
    {
        "properties":  {
          "my_vector1":  { "type": "knn_vector", "dimension": 2 },
          "my_vector2":  { "type": "knn_vector", "dimension": 4 }
      }
  }
}
```

```
POST _bulk
{ "index": { "_index": "my-index", "_id": "1" } }
{ "my_vector1": [1.5, 2.5], "price": 12.2 }
{ "index": { "_index": "my-index", "_id": "2" } }
{ "my_vector1": [2.5, 3.5], "price": 7.1 }
{ "index": { "_index": "my-index", "_id": "3" } }
{ "my_vector1": [3.5, 4.5], "price": 12.9 }
{ "index": { "_index": "my-index", "_id": "4" } }
{ "my_vector1": [5.5, 6.5], "price": 1.2 }
{ "index": { "_index": "my-index", "_id": "5" } }
{ "my_vector1": [4.5, 5.5], "price": 3.7 }
{ "index": { "_index": "my-index", "_id": "6" } }
{ "my_vector2": [1.5, 5.5, 4.5, 6.4], "price": 10.3 }
{ "index": { "_index": "my-index", "_id": "7" } }
{ "my_vector2": [2.5, 3.5, 5.6, 6.7], "price": 5.5 }
{ "index": { "_index": "my-index", "_id": "8" } }
{ "my_vector2": [4.5, 5.5, 6.7, 3.7], "price": 4.4 }
{ "index": { "_index": "my-index", "_id": "9" } }
{ "my_vector2": [1.5, 5.5, 4.5, 6.4], "price": 8.9 }
```

https://docs.aws.amazon.com/ko_kr/opensearch-service/latest/developerguide/knn.html
https://opensearch.org/docs/latest/search-plugins/knn/knn-index/

Vector DB로써의 OpenSearch

- 시맨틱 벡터 검색

```
GET my-index/_search
{
  "size": 2,
  "query": {
    "knn": {
      "my_vector2": {
        "vector": [2, 3, 5, 6],
        "k": 2
      }
    }
  }
}
```

혼합 검색 (Hybrid search)

```
GET my-index/_search
{
  "size": 2,
  "query": {
    "knn": {
      "my_vector2": {
        "vector": [2, 3, 5, 6],
        "k": 2
      }
    }
  },
  "post_filter": {
    "range": {
      "price": {
        "gte": 6,
        "lte": 10
      }
    }
  }
}
```

OpenSearch 지원 벡터 엔진과 인덱싱

	NMSLIB-HNSW	FAISS-HNSW	Lucene-HNSW
Max dimension	16,000	16,000	1024
Filter	Post-filter	Pre-filter and Post-filter	Filter while search
Distance formula	l2, innerproduct, cosinesimil, l1, linf	l2, innerproduct	l2, cosinesimil
Indexing latency	Low	Low	Low
Query latency & quality	Low latency & high quality	Low latency & high quality	High latency & high quality
Vector compression	Flat	Flat	Flat
Memory consumption	High	High	High

OpenSearch 서버리스 벡터 엔진 정식 출시

OpenSearch 서버리스 자동 용량 관리

- 1 OCU는 1 vCPU, 6 GB RAM, 120GB of Amazon EBS 볼륨 지원
- OCU 단위로 유사성 검색 쿼리 수집 및 실행
- OCU 단위로 128개 차원의 경우 2백 만개 벡터 처리
- 용량 자동 조정 기능을 제공하여 재색인 없이 10억 벡터 규모로 확장 가능

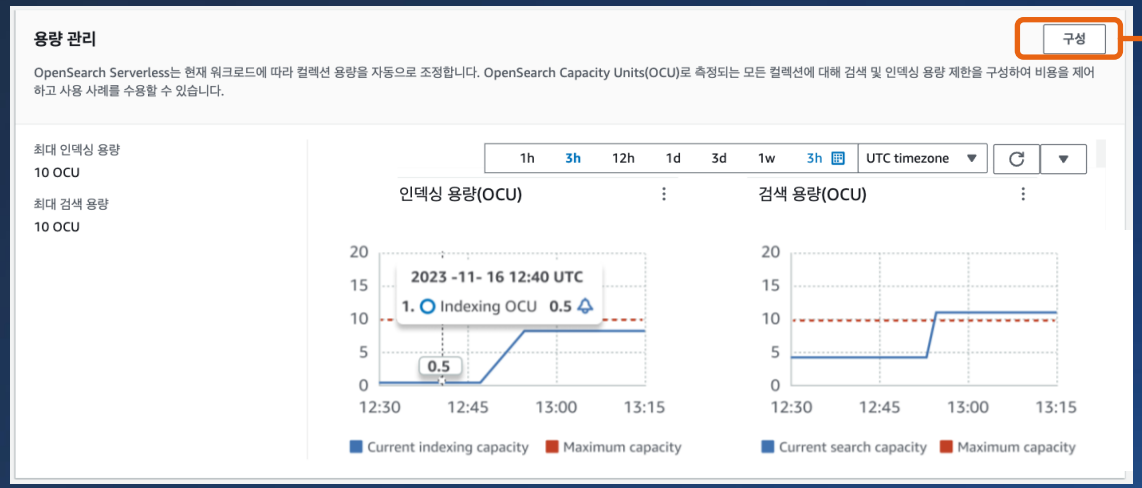

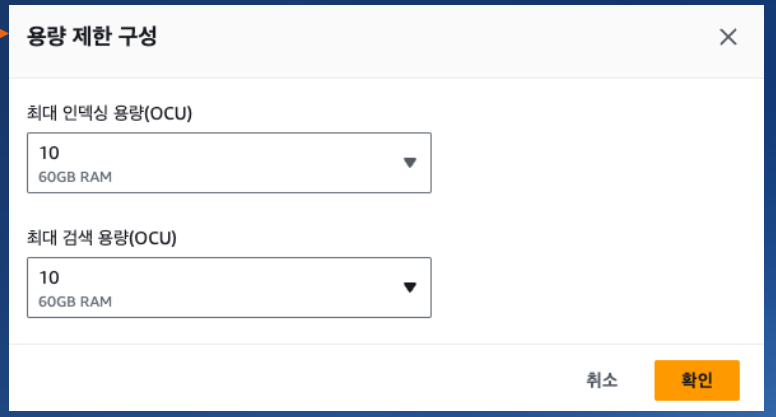

Amazon Aurora

Amazon RDS

PostgreSQL

pgVector 확장

Aurora PostgreSQL 15.3, 14.8, 13.11, 12.15 and higher
Amazon RDS running PostgreSQL 15.2 and higher

벡터 저장소

오픈 소스 pgvector 확장(extension) 사용 가능

벡터 인덱싱

IVFFlat, HNSW 인덱스 지원

유사성 검색 및 벡터 거리 측정

K-NN, ANN 알고리즘 사용 가능
유클리드 <-> , 코사인 유사성(<=>), 내적(<#>) 지원

메타데이터 저장 및 조인

데이터, 임베딩, 메타데이터를 같은 테이블에 저장 가능
또는 임베딩과 다른 테이블간의 조인 가능

뛰어난 성능·확장성·가용성·비용 효율성

고사양 상용 데이터베이스의 성능, 확장성, 가용성에
오픈소스 데이터베이스의 비용 효율성의 이점 활용 가능

Aurora I/O 최적화에서의 벡터 검색 성능 향상

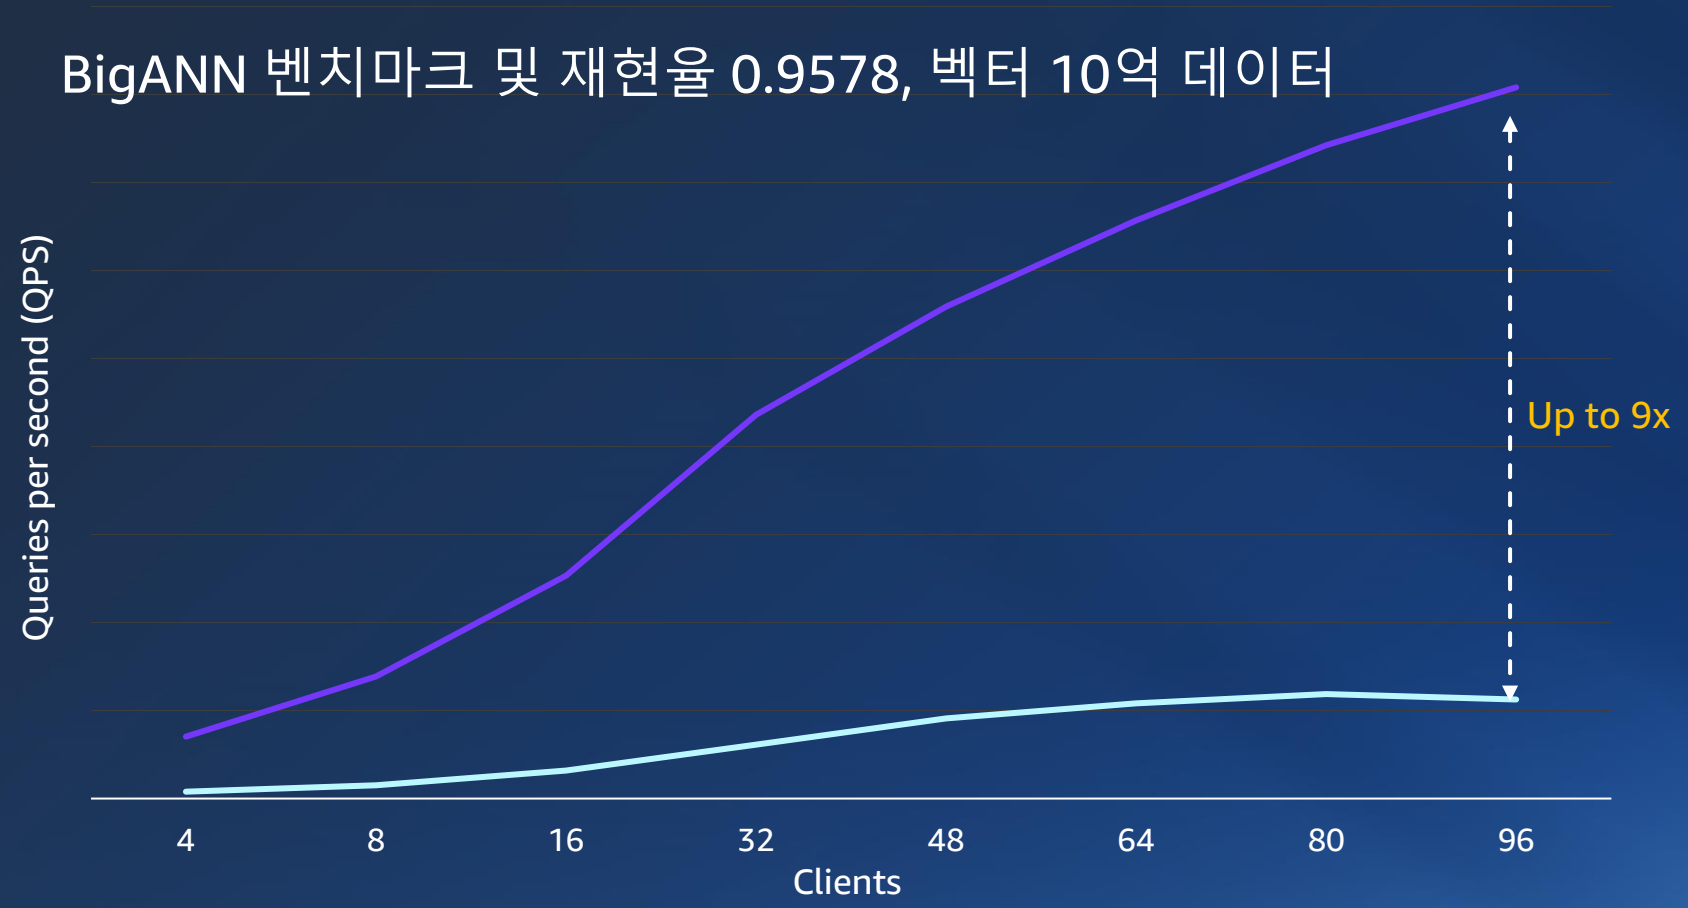

Database size: 1.28TB (Data: 560 GB, Index: 720GB)

pgvector v0.5: HNSW index

AWS Graviton3 타입에서의 벡터 검색 성능 향상

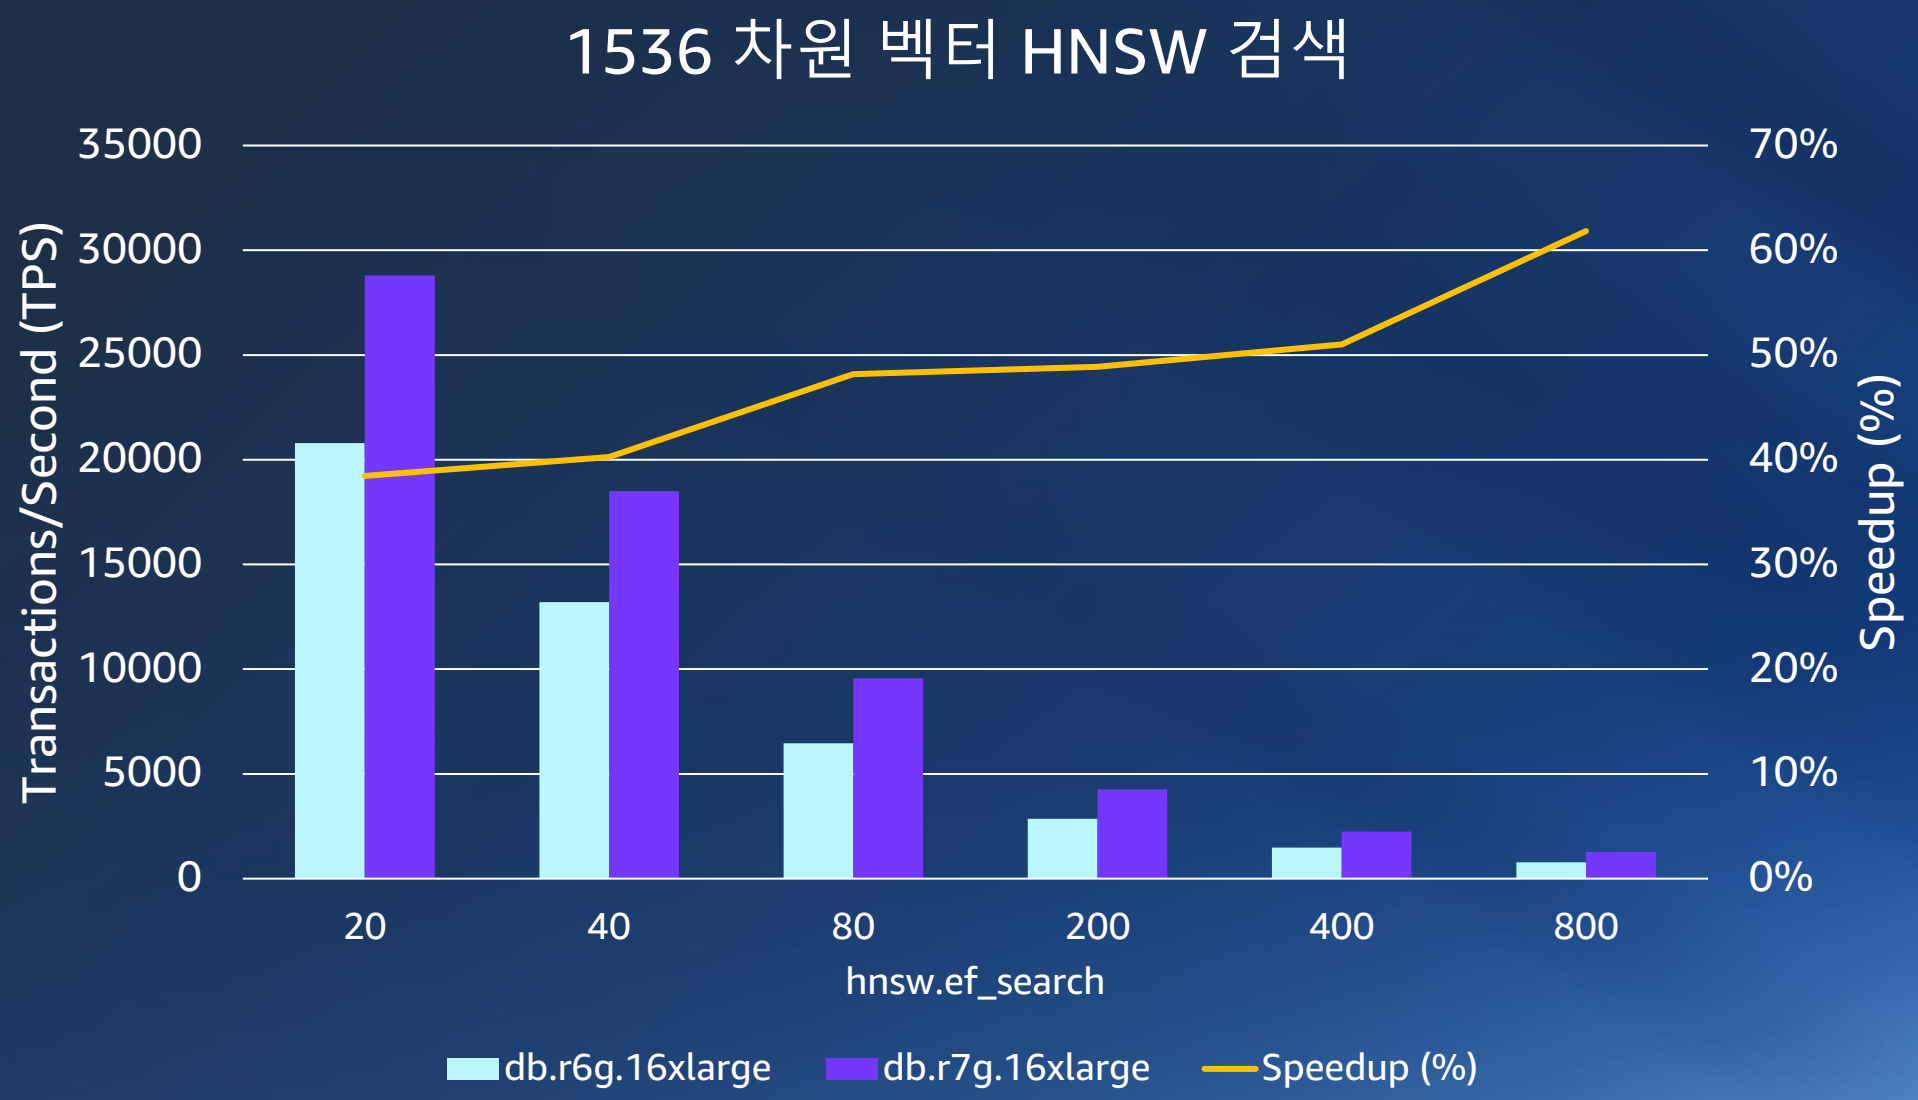

Amazon MemoryDB for Redis 벡터 검색 (Preview)

Redis v7.1용 MemoryDB와 함께 사용 가능

미국 동부(버지니아 북부), 미국 동부(오하이오), 미국 서부(오레곤), 아시아 태평양(도쿄)) 및 유럽(아일랜드) 리전에서 지원

높은 처리량과 높은 재현율이 필요한 애플리케이션을 위한 AWS에서 가장 빠른 벡터 검색

밀리초 단위의 검색 및 업데이트 소요 시간

최대 419GB 메모리 및 32,768개 차원 지원

수백만 개의 임베딩 저장 Redis JSON 및 해시 key

FLAT 및 HNSW 인덱싱

유클리드, 코사인 및 내적 유사성 검색 지원

MemoryDB 벡터 검색 사용 설정

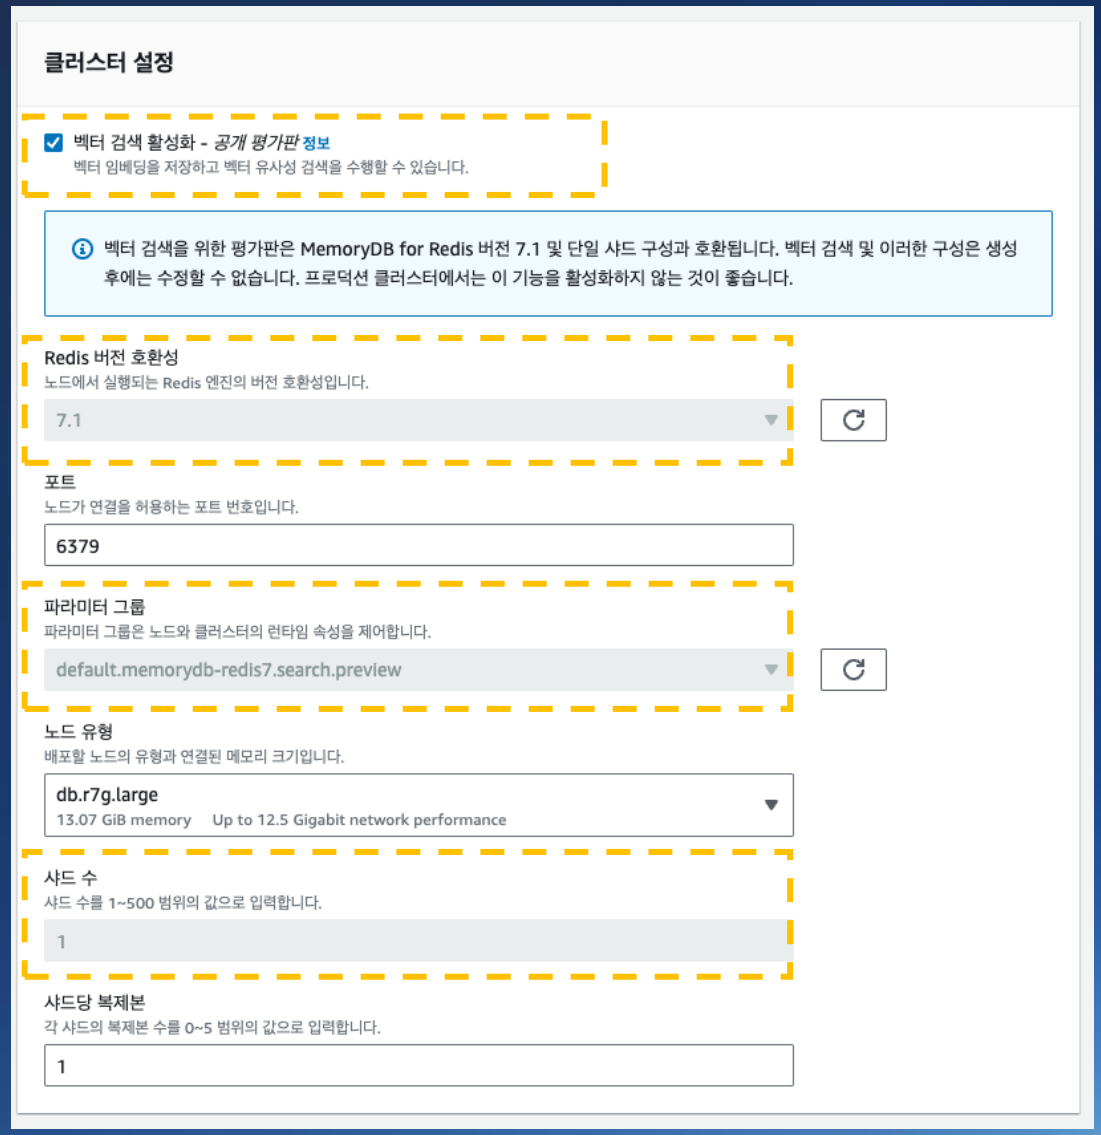

MemoryDB 벡터 인덱스 생성

```
FT.CREATE my_index ON HASH // 또는 JSON
      SCHEMA field_name VECTOR HNSW 6   // 또는 FLAT
      TYPE FLOAT32 DIM 128 DISTANCE_METRIC L2 // 또는 IP , COSINE
```

```
FT.CREATE my_index ON HASH
      SCHEMA field_name VECTOR HNSW 6
      TYPE FLOAT32 DIM 128 DISTANCE_METRIC COSINE
```

MemoryDB 벡터 검색

```
FT.SEARCH my_index "*=>[KNN 10 @vec $BLOB]"
    PARAMS 2 BLOB "\x12\xa9\xf5\x6c....."

FT.SEARCH my_index "@Qty:[0 100]=>[KNN 10 @vec $BLOB]"
    PARAMS 2 BLOB "\x12\xa9\xf5\x6c....."

FT.SEARCH my_index "@City:{New York | Boston}
    =>[KNN 10 @vec $BLOB]"
    PARAMS 2 BLOB "\x12\xa9\xf5\x6c....."
```

MemoryDB의 매우 탁월한 처리량과 재현율

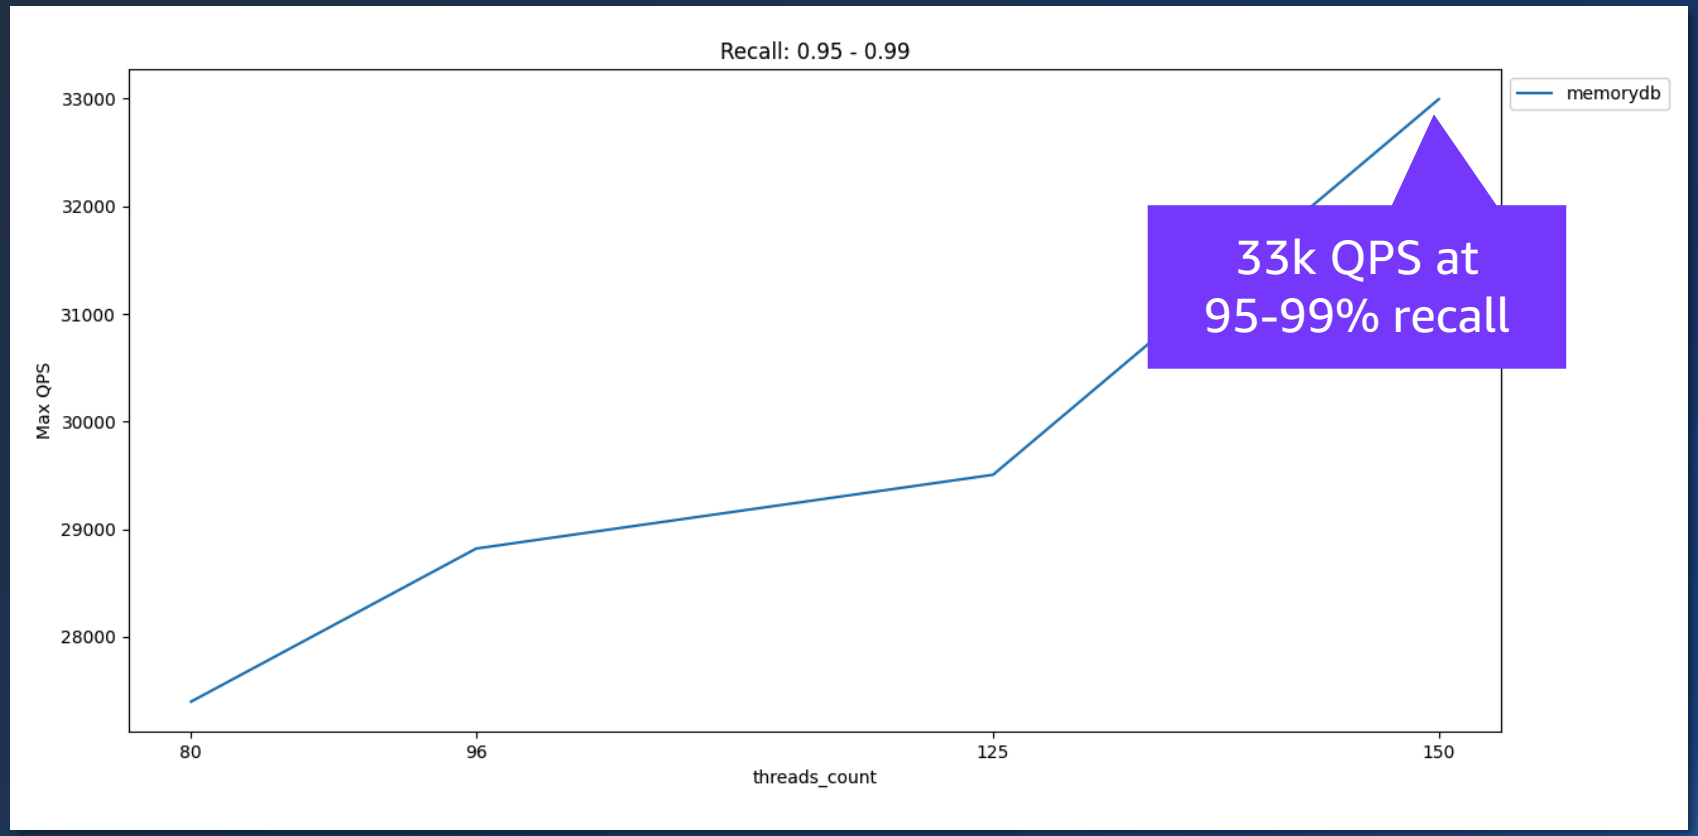

MemoryDB 구성

- 읽기 전용 복제본 – 5 개
- r6g.8xlarge
- vCPU 32개, 256GB 메모리
- 128개 차원의 10M 벡터
- HNSW 인덱싱

Amazon DocumentDB (MongoDB 호환) 벡터 검색

Engine version 5.0.0 지원

문서와 벡터의 통합 저장소

문서 저장소와 벡터 데이터베이스를 통합하여 별도의 저장소 관리 필요성 제거

벡터 검색 시 동일한 DB와 문법 사용

데이터 복제, Integration 코드 작성 필요성 제거를 통한 유지 관리 비용 효율성 달성

다차원 벡터와 거리 측정 알고리즘 지원

16,000 차원 지원 (인덱싱할 경우 2,000 차원 지원)
유클리드, 코사인 유사성, 내적 알고리즘 지원

IVFFLAT 벡터 인덱스 지원

IVFFlat 인덱스 지원, List와 Probes 튜닝 파라미터를 통한 향상된 쿼리 성능 제공

차후 HNSW 인덱스도 지원 예정

DocumentDB 벡터 검색 사용

1. 벡터 임베딩 대량 입력

```
db.collection.insertMany([
{sentence: “나는 고양이와 강이지를 좋아한다.” vectorField: [0.82421875, -0.6953125,...]},
{sentence: " 내 강아지는 매우 귀엽다.” vectorField: [0.05883789, -0.020385742,...]},
{sentence: " 나는 펜으로 글을 쓴다", vectorField: [-0.020385742, 0.32421875,...]}, ... ]);
```

2. 벡터 인덱스 생성

```
db.collection.createIndex (
{ vectorField: "vector" },
{ "name": "index name",
  "vectorOptions": {
       "dimensions": 100, // 벡터 데이터 차원 수
       "similarity": "euclidean", // 또는 cosine, dotProduct 설정 가능
       "lists": 100 } // IVFFlat의 버킷 수
 } );
```

DocumentDB 벡터 검색 사용

3. 벡터 검색

```
db.collection.aggregate ({
$search: {
  "vectorSearch": {
  "vector": [0.82421875, -0.6953125,...], // “나는 동물을 좋아한다”를 검색
  "path": vectorField,
  "k": 5, // 5개의 유사 벡터 검색 결과 반환
  "similarity": "euclidean",
  "probes": 1 // 검색 대상 버킷 수}
} });
```

Amazon Neptune Analytics 벡터 검색

Neptune Analytics는 대규모 그래프 데이터를 몇 초 만에 분석할 수 있는 메모리 최적화된 그래프 데이터베이스 엔진

Neptune Analytics Notebook에서 Neptune 데이터베이스의 그래프 데이터, Amazon S3 그래프 데이터를 로드하여 분석가능

openCyper 기반 최적화된 분석 그래프 알고리즘을 사용. 그래프 분석과 벡터 검색을 같이 활용하여 데이터의 숨겨진 관계를 더 쉽게 발견

Amazon Neptune Analytics에서의 벡터 검색 설정

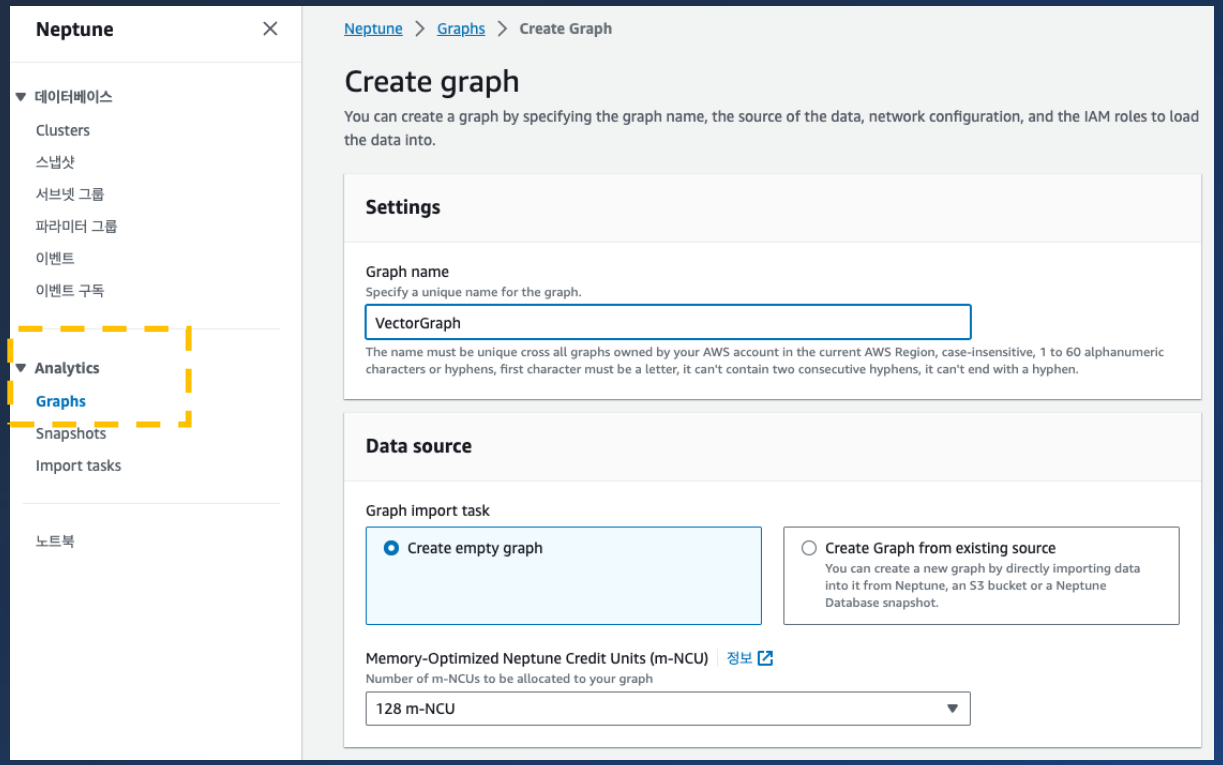

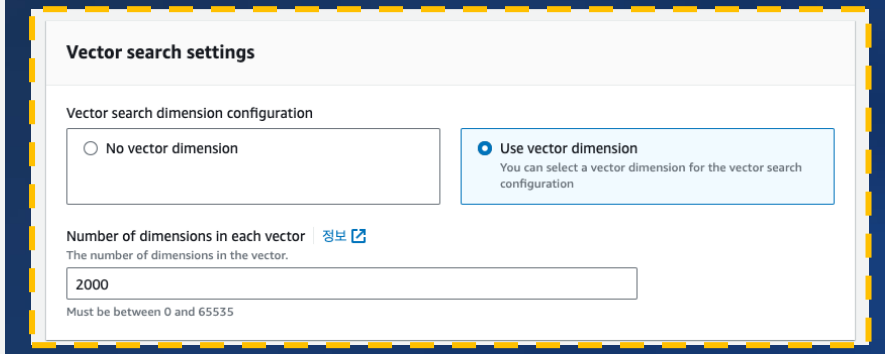

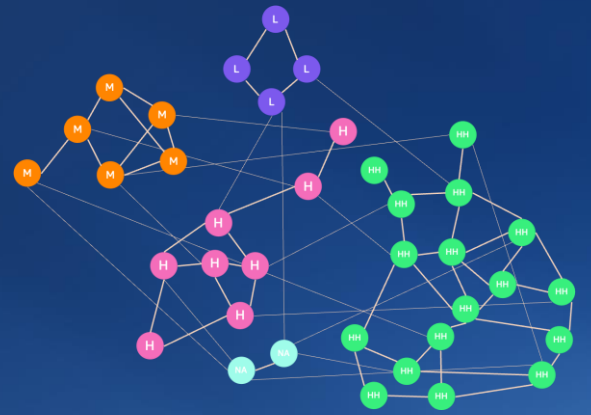

* m-NCU : 메모리 최적화 Neptune 컴퓨팅 단위, 1024 m-NCU까지 지원

Neptune Analytics의 그래프 검색

```
// Algorithms
MATCH (n:airport {country: 'US'})

WITH collect(n) as airports, n.region as region

CALL neptune.algos.bfs.levels(n)

YIELD node, level

RETURN node, level
```

Neptune Analytics에서의 그래프 검색과 벡터 검색

```
MATCH (n:Book {name: 'Travel: Portugal'})

// 1 //
CALL neptune.vectors.topKByNode(n, { topK: 10 } )
YIELD node, score, rank

// 2 //
MATCH p=(node)-[*1..3]->(suspicious)

WHERE (suspicious: seller OR suspicious: lister OR suspicious: buyer)

// 3 //
RETURN n, collect(p), score, rank

ORDER BY rank DESC
```

Knowledge bases for Amazon Bedrock

- 검색 증강 생성(RAG)에 대한 기본 지원

FM을 데이터 소스에 안전하게 연결하여 보다 관련성 높은 응답 결과 제공

수집ingestion, 검색retrieval, 증강augmentation을 포함한 완전 관리형 RAG 워크플로

멀티 턴 대화를 위한 빌트인 세션 컨텍스트 관리 기능

검색을 통한 자동 인용으로 투명성 향상

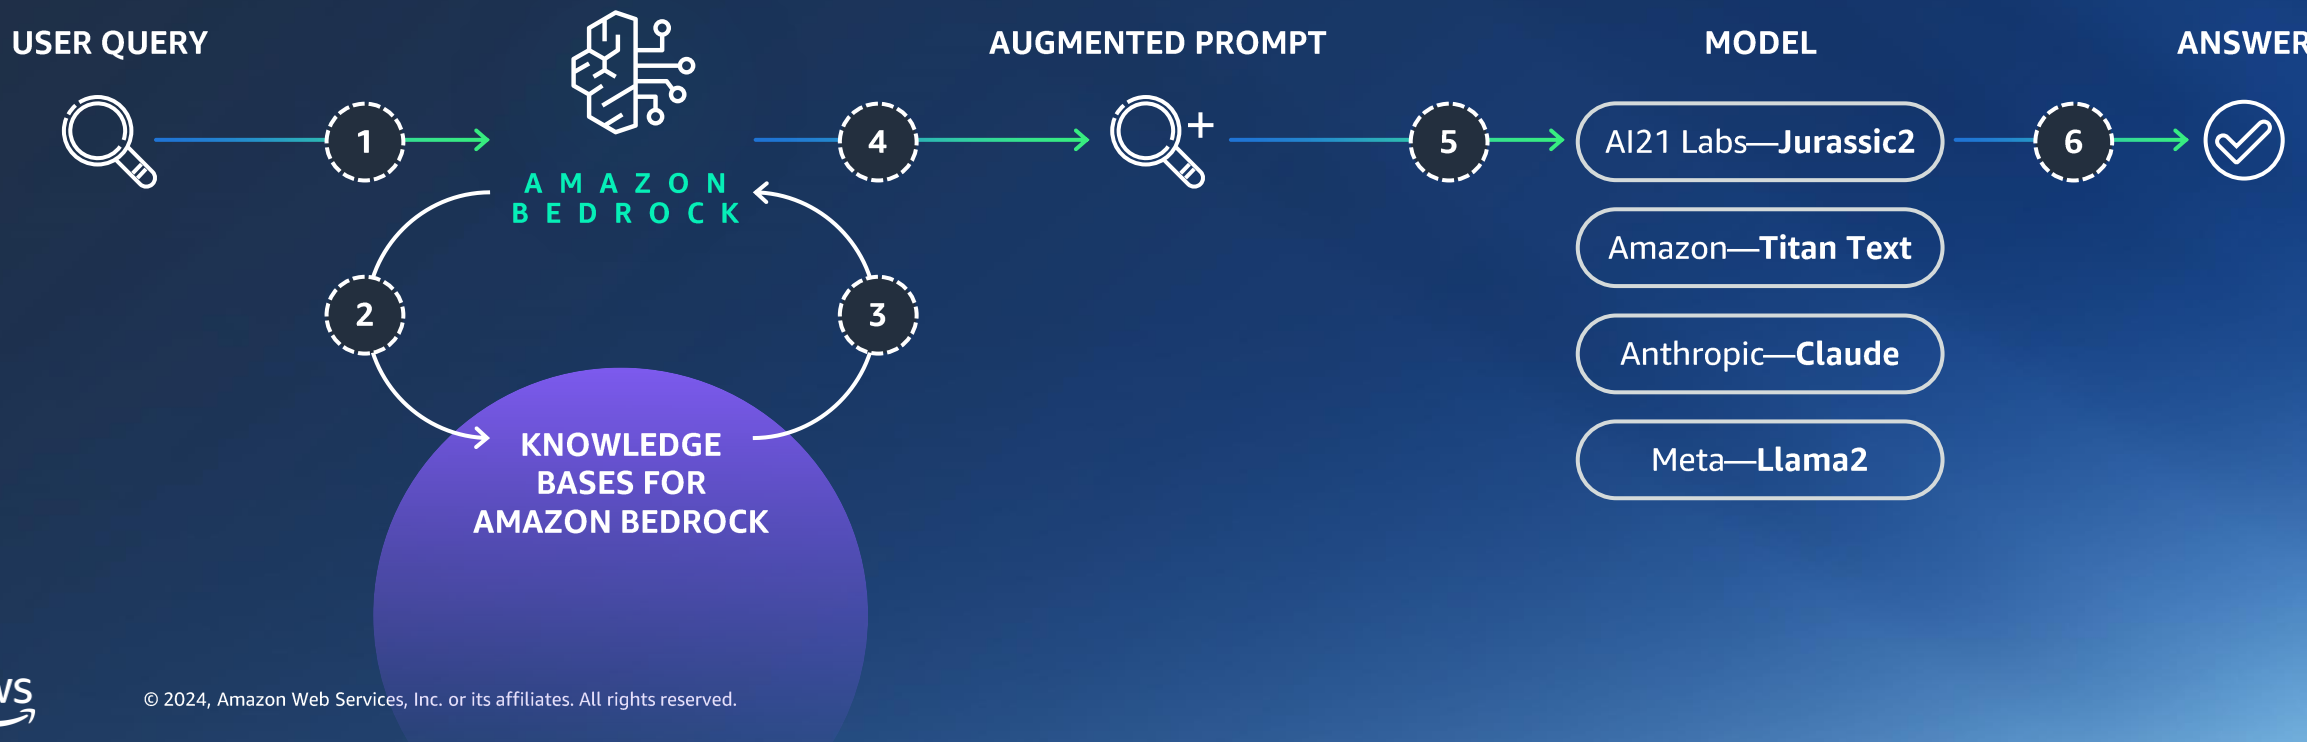

Amazon Bedrock 지원 벡터 데이터 베이스

Vector Engine For Amazon OpenSearch Serverless

Redis Enterprise Cloud

Pinecone

Amazon Aurora

COMING SOON

MongoDB

AWS의 완전 관리형 End to End RAG 워크플로우

아마존 베드락 지식 베이스 데모

AWS vector data store options for RAG

Amazon Aurora/RDS PostgreSQL

기존 PostgreSQL 사용, 또는 관계형 DB 전문성이 있을 경우 적합

- Aurora and RDS PostgreSQL에서 모두 사용 가능한 Open-source pgvector 확장 기능
- 벡터간 정확하고 근사값 거리 조회 가능 , 3 종류 거리 검색 알고리즘 제공
- 기존 도메인 특화 데이터와 로컬에서 조인

Amazon OpenSearch Serverless

NoSQL에 익숙한 경우, 검색 알고리즘기반으로 한 하이브리드 검색 장점

- k-nn plugin을 통해 시맨틱 검색 지원
- 시맨틱 검색과 키워드 검색 (Lexical 검색) 결합한 하이브리드 검색 가능
- 수평적 확장 가능 (Horizontally scalable / shading)

Amazon MemoryDB for Redis

초저지연 벡터 검색 가능

- 시멘틱 검색과 키워드 검색 결합한 하이브리드 검색 가능
- 벡터간 정확하고 근사값 거리 조회 가능 , 3 종류 거리 검색 알고리즘 제공

Amazon DocumentDB

문서 기반 데이터를 활용한 벡터 검색

- 별도의 인프라 관리 필요성 제거
- 2,000 차원, 3 거리 검색, 2 튜닝 파라미터(Lists and Probes)
- 쿼리 성능과 비용 효율성 개선

Amazon Neptune Analytic

그래프 검색과 벡터 검색을 결합한 데이터의 숨은 패턴 용이

- LLM에서 훈련된 임베딩을 저장하고 그래프 쿼리에서 검색
- • 넵튜의 LangChain 통합을 통한 자연어 그래프 쿼리

벡터 데이터베이스 선택 시 고려사항

- 친숙함 Familiarity
- 구현의 용이성 Ease of implementation
  - Abstractions
  - Integrations
- 확장성 Salability
  - Vector dimensions supported
  - Number of embeddings
- 성능 Performance
  - Queries per second (QPS)
  - Recall rate
- 유연성

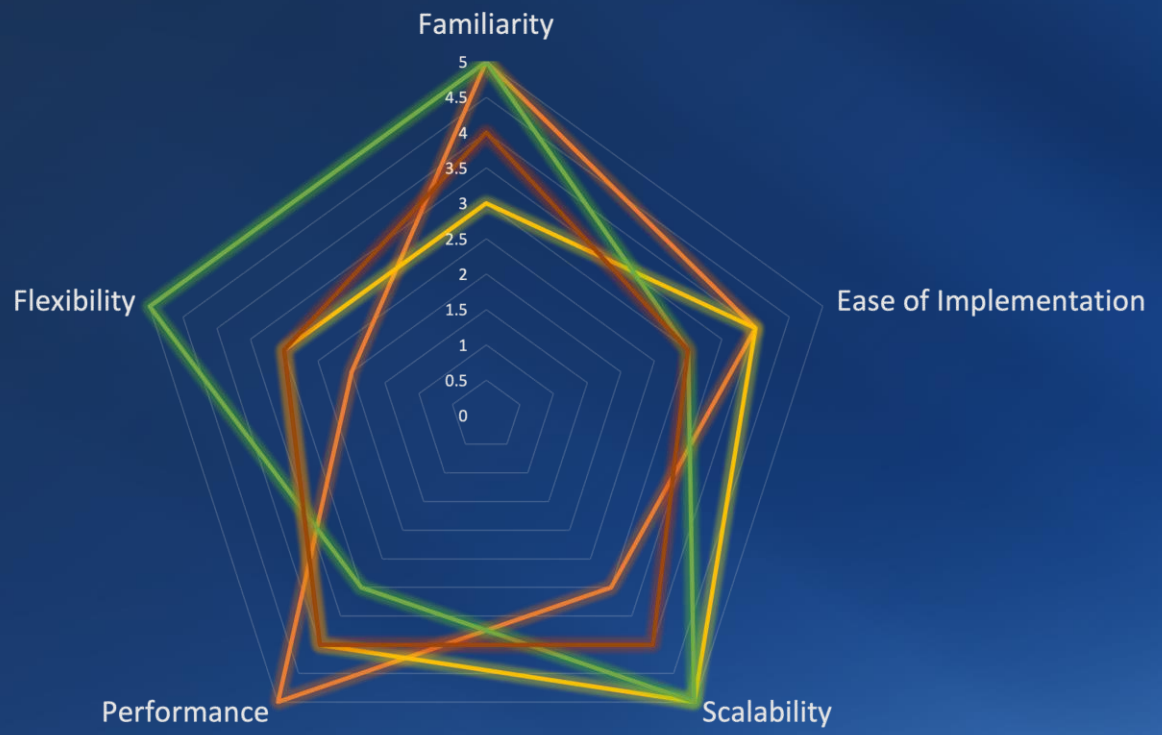

AWS 벡터 데이터베이스 비교

	친숙성	구현 용이성	확장성	성능	알고리즘	거리 측정
Aurora/RDS PostgreSQL with pgvector	**Technology:** PostgreSQL **Query language:** SQL	**Abstraction:** AuroraML, Amazon Bedrock integration **Integration:** Zero-ETL*, federated queries	**# of vectors:** > 1 billion **Dimensions:** 16,000 (max. 2000 indexed)	Recall: variable (HNSW ef_search, IVFFLAT probes) Throughput: thousands of QPS and more	**Indexing:** ivfflat, HNSW **Enrichment:** Joins	Euclidean Cosine similarity Inner product
Vector engine for OpenSearch Serverless (with k-NN plugin)	**Technology:** OpenSearch, ElasticSearch **Query language:** REST API	**Abstraction:** Neural Search plugin*, Amazon Bedrock integration **Integration:** OpenSearch Ingestion	**# of vectors:** > 1 billion **Dimensions:** 16,000 (max. 1024 for Lucene engine)	Recall: variable (segments, NMSLIB ef_search) Throughput: horizontally scalable	**Indexing:** NMSLIB and FAISS (HNSW, ivfflat) **Enrichment:** Keyword search+ semantic search	Euclidean Cosine similarity Dot-product
MemoryDB*	**Technology:** Redis **Query language:** API	**Abstraction:** Neural Search plugin **Integration:** MemoryDB Ingestion	**Dimensions:** 32,768	Recall: variable (Flat & HNSW use parameter INITIAL_CAP) Throughput: Single Shard, no horizontally scalable for now	**Indexing:** HNSW, FLAT **Enrichment:** Hash search+ semantic search	Euclidean Cosine similarity Dot-product
DocumentDB	**Technology:** MongoDB, DocumentDB **Query language:** API	**Abstraction:** Neural Search plugin **Integration:** DocumentDB Ingestion	**Dimensions:** 16,000 (max. 2000 indexed)	Recall: variable [IVFFLAT list sqrt(# of documents)) IVFFLAT probes sqrt (# of lists, HNSW] Throughput: thousands of QPS and more	**Indexing:** ivfflat, HNSW **Enrichment:** Keyword search+ semantic search	Euclidean Cosine similarity Dot-product
Neptune	**Technology:** PostgreSQL **Query language:** openCypher, Garmin	**Abstraction:** Neural Search plugin **Integration:** Neptune Ingestion	**Dimensions:** 65,535	Recall: variable [IVFFLAT list sqrt(# of documents)) IVFFLAT probes sqrt (# of lists, HNSW] Throughput: thousands of QPS and more	**Indexing:** Graph indexing	Vector Distance =Euclidean (L2 Distance)

ivfflat: Inverted File Index - flat
For more efficient and cost effective workloads

HNSW: Hierarchical Navigable Small World Graphs
For high accuracy, low latency at higher cost (memory requirement)

FAISS: Facebook AI Similarity Search

NMSLIB: Non-Metric Space Library

* in preview

AWS 리소스 허브

AWS가 제공하는 AI/ML 및 생성형 AI에 관한 다양한 자료들을 통해 더욱 심층적으로 학습해보세요!

- 기계 학습 여정 가이드
- 기계 학습의 7가지 주요 사용 사례
- 대규모 기계 학습 개발 현대화 전략 가이드
- 기계 학습으로 혁신적인 비즈니스 성과 달성 가이드
- 생성형 AI를 통해 비즈니스 혁신을 가속화 시키는 6단계 가이드
- 생성형 AI 보안에 대한 4가지 핵심 질문과 가이드
- + 외의 다양한 동영상 학습 자료 및 기술 학습 자료!

https://shorturl.at/wzL13

리소스 허브 방문하기

AWS 교육 및 자격증

AWS Skill Builder에서 AWS 전문가들이 개발한 AI & ML 학습 과정들을 무료로 만나보세요!

여러분의 진도에 맞춰 온디멘드 교육 과정 및 Ramp-Up 가이드 등 다양한 학습 리소스를 이용해 여러분의 기술 역량을 향상시키세요.

업계에서 떠오르는 인공 지능과 기계 학습 및 딥 러닝을 어떻게 클라우드에 적용시킬 수 있는지 배울 수 있습니다.

AWS Certified Machine Learning – Specialty 자격증을 통해 여러분의 전문성을 증명하십시오. AWS Skill Builder 에서 학습하실 수 있습니다.

https://bit.ly/3FnxDH7

Learn your way explore.skillbuilder.aws »

AWS Innovate – AI/ML & Data 특집에 참석해 주셔서 감사합니다.

저희가 준비한 강연, 어떻게 보셨나요?
더 나은 세미나를 위하여 **설문을 꼭 작성해 주세요!**


aws-korea-marketing@amazon.com


twitter.com/AWSKorea


facebook.com/amazonwebservices.ko


youtube.com/AWSKorea


linkedin.com/company/amazon-web-services


twitch.tv/aws

Thank you!